

Análisis Exploratorio de Datos y gráficos depurados

Archibald Emmanuel Carrion Claeys

A. Primera parte

A.1. Información general

Empezamos realizando una lectura de los datos. En este caso, el dataset es un archivo CSV que contiene información sobre Pokémon.

```
df <- (read.csv(file.choose(), header = TRUE, encoding = "UTF-8"))
attach(df)

# Resumen informativo de los datos - tendencias
summary(df)
```

Podemos conseguir información general sobre el dataset usando `str()` y `glimpse()`.

```
# Información básica
str(df)
# glimpse() es una función del paquete dplyr que proporciona una
# vista rápida de los datos
library(dplyr)
glimpse(df)

# adicionalmente tambien existe summary() que nos da un resumen de las
# variables, como cuartiles y datos máximos y mínimos
summary(df)
```

No se agregaron las salidas de los 2 chunks anteriores, ya que son muy extensas, y pueden fácilmente ser consultadas en el archivo csv adjunto. Algunos de los datos más valiosos que se agregará al reporte son los siguientes - attack - defense - hp - weight_kg - height_m

```
summary(df$attack)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	5.00	55.00	75.00	77.86	100.00	185.00

```
summary(df$defense)
```

##	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
##	5.00	50.00	70.00	73.01	90.00	230.00

```
summary(df$hp)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      1.00   50.00   65.00   68.96   80.00  255.00
```

```
summary(df$weight_kg)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.   NA's
##      0.10    9.00   27.30   61.38   64.80   999.90    20
```

```
summary(df$height_m)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.   NA's
##      0.100   0.600   1.000   1.164   1.500   14.500    20
```

Las variables categoricas se pueden obtener usando la función `table()` o `count()`. En R, una variable categórica es aquella que puede tomar un número limitado de valores distintos, representando categorías o grupos.

```
# Variables categoricas
```

```
table(df$type1)
```

```
##
##      bug      dark  dragon electric   fairy fighting    fire  flying
##      72       29      27       39      18       28      52       3
##      ghost  grass  ground      ice  normal   poison  psychic   rock
##      27      78      32      23     105      32      53      45
##      steel   water
##      24      114
```

```
table(df$type2)
```

```
##
##              bug      dark  dragon electric   fairy fighting    fire
##      384       5       21      17       9       29      25      13
##      flying  ghost  grass  ground      ice  normal   poison  psychic
##      95      14      20      34      15       4      34      29
##      rock   steel   water
##      14      22      17
```

```
count(df, type1)
```

```
##      type1  n
## 1      bug  72
## 2      dark 29
## 3     dragon 27
## 4   electric 39
## 5      fairy 18
## 6   fighting 28
## 7        fire 52
```

```
## 8    flying    3
## 9     ghost   27
## 10    grass   78
## 11   ground   32
## 12     ice    23
## 13   normal  105
## 14   poison   32
## 15  psychic   53
## 16    rock    45
## 17   steel    24
## 18    water  114
```

```
count(df, type2)
```


```
##      type2    n
## 1          384
## 2      bug     5
## 3     dark    21
## 4   dragon    17
## 5  electric     9
## 6    fairy    29
## 7  fighting    25
## 8     fire    13
## 9    flying    95
## 10   ghost    14
## 11   grass    20
## 12   ground    34
## 13     ice    15
## 14   normal     4
## 15   poison    34
## 16  psychic    29
## 17    rock    14
## 18   steel    22
## 19   water    17
```

A.2. Histogramas

Un histograma es una representación gráfica de la distribución de un conjunto de datos que muestra la frecuencia de los valores en intervalos o “bins”. Se usa para analizar la distribución de una variable continua, como la altura o el peso de los Pokémon.


Histograma de la variable hp

```
# Por ejemplo, el siguiente código construye un histograma para la variable hp
hist(df$hp)
```




```
# Se puede hacer un poco más claro agregando título y etiquetas:  
hist(df$hp,  
      main = "Distribución de variable hp",  
      xlab = "HP",  
      col = "lightblue",  
      border = "black")
```

Distribución de variable hp



Histograma de la variable attack


```
# Histograma de la variable attack
hist(df$attack,
      main = "Distribución de variable attack",
      xlab = "Attack",
      col = "lightblue",
      border = "black")
```



Histograma de la variable defense

```
# Histograma de la variable defense
hist(df$defense,
      main = "Distribución de variable defense",
      xlab = "Defense",
      col = "lightblue",
      border = "black")
```


Distribución de variable defense



Histograma de la variable weight_kg

```
# Histograma de la variable weight_kg
hist(df$weight_kg,
      main = "Distribución de variable weight_kg",
      xlab = "Weight (kg)",
      col = "lightblue",
      border = "black")
```


Distribución de variable weight_kg



Histograma de la variable height_m

```
# Histograma de la variable height_m
hist(df$height_m,
      main = "Distribución de variable height_m",
      xlab = "Height (m)",
      col = "lightblue",
      border = "black")
```


Distribución de variable height_m




A.3. Boxplots (cajas y bigotes)

Un boxplot es una representación gráfica que muestra la distribución de un conjunto de datos a través de sus cuartiles. Los boxplots son útiles para identificar la presencia de valores atípicos (outliers) y para comparar la distribución de diferentes grupos.

Boxplot de la variable attack

```
boxplot(attack ~ type1,  
        data = df,  
        main = "Ataque por Tipo de Pokémon",  
        xlab = "Tipo",  
        ylab = "Ataque",  
        las = 2,  
        col = "lightgreen")
```


Ataque por Tipo de Pokémon



Boxplot de la variable defense por tipo de Pokémon

```
boxplot(defense ~ type1,  
  data = df,  
  main = "Defensa por Tipo de Pokémon",  
  xlab = "Tipo",  
  ylab = "Defensa",  
  las = 2,  
  col = "lightgreen")
```


Defensa por Tipo de Pokémon



Boxplot de la variable hp por generación de Pokémon

```
boxplot(hp ~ generation,
  data = df,
  main = "HP por Generación de Pokémon",
  xlab = "Generación",
  ylab = "HP",
  las = 1,
  col = "lightblue")
```

HP por Generación de Pokémon




A.4. Gráficos de dispersión

Un gráfico de dispersión (scatter plot) es una representación gráfica que muestra la relación entre dos variables cuantitativas. Los puntos en el gráfico representan pares de valores de las dos variables, lo que permite observar patrones, tendencias y posibles correlaciones entre ellas, o en el caso contrario, si no existe relación entre las variables.

Gráfico de dispersión entre ataque y defensa

```
# Por ejemplo, el siguiente código construye un gráfico de dispersión  
# entre attack y defense.  
plot(df$attack,  
      df$defense)
```



```
# Se puede hacer un poco más claro agregando título y etiquetas:  
plot(df$attack,  
      df$defense,  
      main = "Ataque vs Defensa",  
      xlab = "Ataque",  
      ylab = "Defensa",  
      col = "darkred")
```




Gráfico de dispersión entre attack y hp

```
# Gráfico de dispersión entre attack y hp  
plot(df$attack,  
      df$hp,  
      main = "Ataque vs HP",  
      xlab = "Ataque",  
      ylab = "HP",  
      col = "darkblue")
```





Gráfico de dispersión entre defense y hp

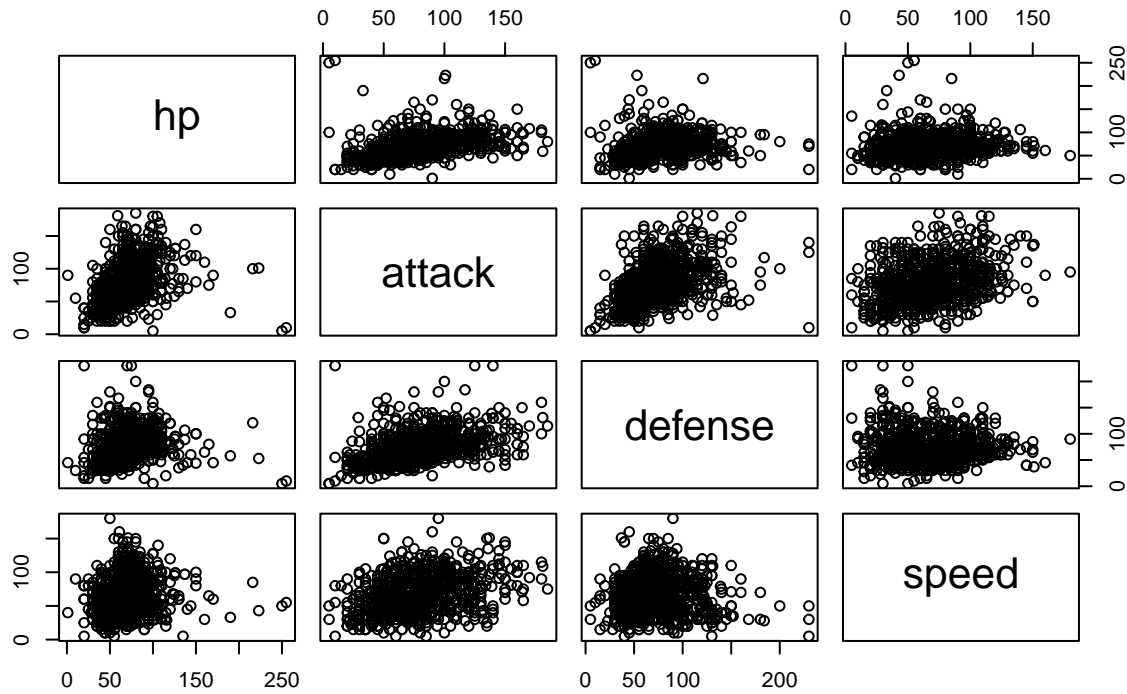
```
# Gráfico de dispersión entre defense y hp
plot(df$defense,
      df$hp,
      main = "Defensa vs HP",
      xlab = "Defensa",
      ylab = "HP",
      col = "darkgreen")
```



De la misma manera se pueden generar varios gráficos simultáneamente

```
# Matrices de dispersión dos a dos para hp, attack, defense y speed.  
pairs(df[, c("hp", "attack", "defense", "speed")],  
      main = "Matrices de Dispersión")
```


Matrices de Dispersión



B. Segunda parte

instalación de librerías necesarias

Instalar los paquetes:

```
# instalar las siguientes librerías si no están instaladas
# install.packages(c("dplyr",
#                    "ggplot2",
#                    "gridExtra",
#                    "tidyr",
#                    "reshape2",
#                    "RColorBrewer",
#                    "ggrepel"))
```

Cargas los paquetes:

```
library(dplyr)
library(ggplot2)
library(gridExtra)
library(tidyr)
library(reshape2)
library(RColorBrewer)
library(ggrepel)
```

Una timble en R es una versión mejorada de un data frame, que proporciona una forma más legible y fácil de trabajar con los datos. Las timbles son parte del paquete dplyr y están diseñadas para ser más eficientes y amigables para el usuario.

```
df <- tibble::as_tibble(df)
colnames(df)[25] <- "classification"
df$capture_rate <- as.numeric(df$capture_rate)
head(df)
```

```
## # A tibble: 6 x 40
##   abilities          against_bug against_dark against_dragon against_electric
##   <chr>              <dbl>         <dbl>         <dbl>         <dbl>
## 1 ['Overgrow', 'Chloro~      1             1             1             0.5
## 2 ['Overgrow', 'Chloro~      1             1             1             0.5
## 3 ['Overgrow', 'Chloro~      1             1             1             0.5
## 4 ['Blaze', 'Solar Pow~    0.5             1             1             1
## 5 ['Blaze', 'Solar Pow~    0.5             1             1             1
## 6 ['Blaze', 'Solar Pow~    0.25            1             1             2
## # i 35 more variables: against_fairy <dbl>, against_fight <dbl>,
## #   against_fire <dbl>, against_flying <dbl>, against_ghost <dbl>,
## #   against_grass <dbl>, against_ground <dbl>, against_ice <dbl>,
## #   against_normal <dbl>, against_poison <dbl>, against_psychic <dbl>,
## #   against_rock <dbl>, against_steel <dbl>, against_water <dbl>, attack <int>,
## #   base_egg_steps <int>, base_happiness <int>, base_total <int>,
## #   capture_rate <dbl>, classification <chr>, defense <int>, ...
```

Como ese timble contiene muchos datos, solo usaremos un subconjunto de las columnas pra realizar nuestra EDA.

```
df <- select(df, name, classification, hp, weight_kg,
             height_m, speed, attack, defense,
             sp_attack, sp_defense, type1, type2,
             abilities, generation, is_legendary,
             capture_rate)
head(df)
```

```
## # A tibble: 6 x 16
##   name      classification    hp weight_kg height_m speed attack defense sp_attack
##   <chr>    <chr>          <int>    <dbl>    <dbl> <int> <int> <int>    <int>
## 1 Bulbas~ Seed Pokémon     45     6.9     0.7   45   49   49     65
## 2 Ivysaur Seed Pokémon     60    13     1    60   62   63     80
## 3 Venusa~ Seed Pokémon     80   100     2    80  100  123    122
## 4 Charma~ Lizard Pokémon    39    8.5     0.6   65   52   43     60
## 5 Charme~ Flame Pokémon    58    19     1.1   80   64   58     80
## 6 Chariz~ Flame Pokémon    78   90.5     1.7  100  104   78    159
## # i 7 more variables: sp_defense <int>, type1 <chr>, type2 <chr>,
## #   abilities <chr>, generation <int>, is_legendary <int>, capture_rate <dbl>
```

B.1. Gráficos de densidad de varios atributos de Pokémon.

Un diagrama de densidad es una representación gráfica que muestra la distribución de una variable continua a través de una curva suave (suavizado del nucleo). Es útil para visualizar la forma de la distribución y la concentración de los datos en diferentes rangos de valores.

```

density_hp <- ggplot(data = df, aes(hp)) +
  geom_density(col = "white", fill = "pink", alpha = 0.8) +
  ggtitle("Densidad de Hit Points o Vida")

density_speed <- ggplot(data = df, aes(speed)) +
  geom_density(col = "white", fill = "darkorchid", alpha = 0.8) +
  ggtitle("Densidad de velocidad")

density_attack <- ggplot(data = df, aes(attack)) +
  geom_density(col = "white", fill = "orange", alpha = 0.7) +
  ggtitle("Densidad características ofensivas")

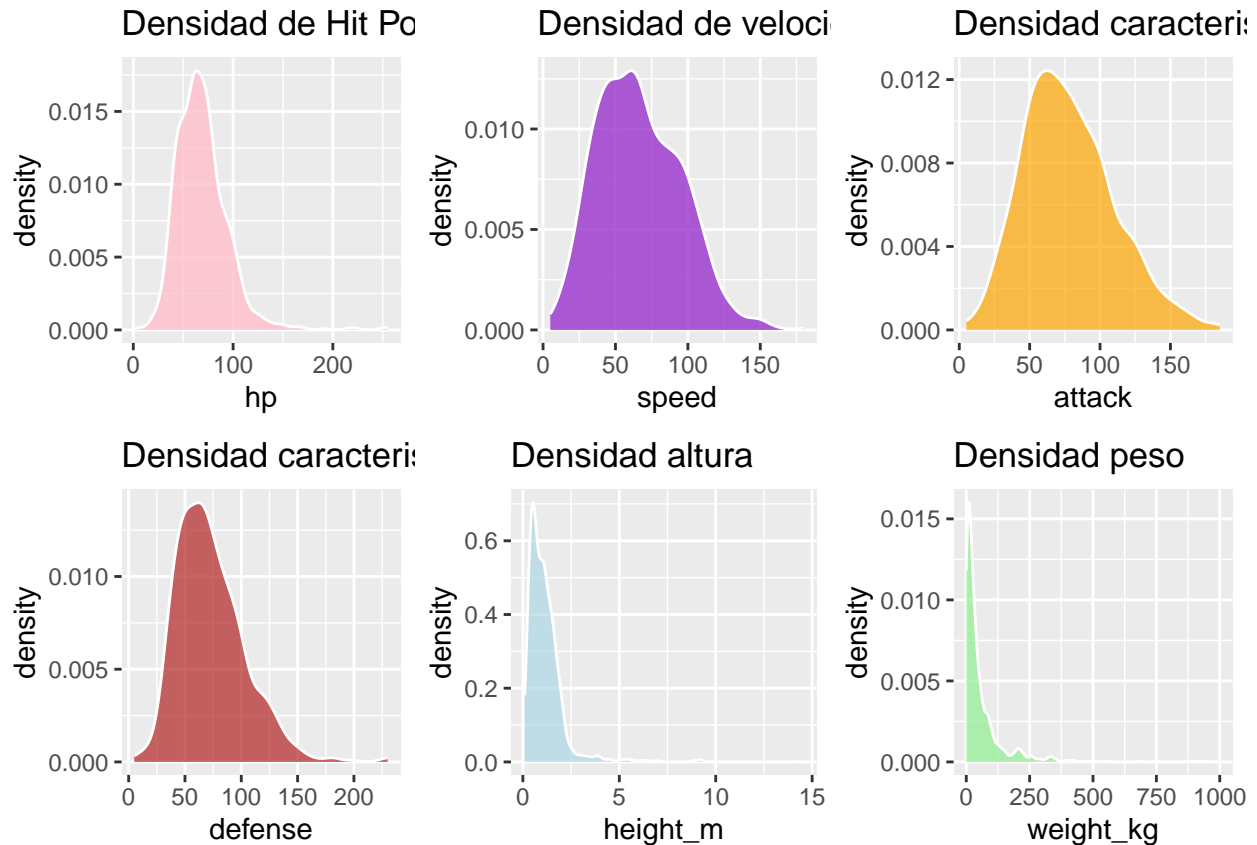
density_defense <- ggplot(data = df, aes(defense)) +
  geom_density(col = "white", fill = "firebrick", alpha = 0.7) +
  ggtitle("Densidad características defensivas")

density_height <- ggplot(data = df, aes(height_m)) +
  geom_density(col = "white", fill = "lightblue", alpha = 0.7) +
  ggtitle("Densidad altura")

density_weight <- ggplot(data = df, aes(weight_kg)) +
  geom_density(col = "white", fill = "lightgreen", alpha = 0.7) +
  ggtitle("Densidad peso")

grid.arrange(density_hp, density_speed, density_attack,
             density_defense, density_height, density_weight,
             ncol = 3, nrow = 2)

```




B.2. Diagramas de Barras

Un diagrama de barras es una representación gráfica que muestra la frecuencia o cantidad de diferentes categorías o grupos. Cada barra representa una categoría y su altura (o longitud) indica la cantidad o frecuencia de esa categoría. Es muy similar a un histograma, pero en lugar de mostrar la distribución de una variable continua, muestra la frecuencia de categorías discretas.

Número de Pokémon basado en su tipo primario (type1) y secundario (type2)

```
ggplot(data=df, aes(type1)) +
  geom_bar(aes(fill = ..count..), alpha = 0.85) +
  scale_fill_gradient(low = "lightblue", high = "darkblue") +
  # Gradiente de colores
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  ggtitle("Distribucion basados en Tipo 1") +
  coord_flip()
```


```
## Warning: The dot-dot notation ('..count..') was deprecated in ggplot2 3.4.0.
## i Please use 'after_stat(count)' instead.
## This warning is displayed once every 8 hours.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.
```



Vemos que el tipo mas comun es Water, Normal, Grass y Bug.


Diagrama de barras para el tipo secundario (type2)

```
ggplot(data = df, aes(type2)) +
  geom_bar(aes(fill = ..count..), alpha = 0.85) +
  scale_fill_gradient(low = "#ffdb67", high = "#8b0000") +
  # Gradiente de colores
  theme(axis.text.x = element_text(angle = 90, hjust = 1)) +
  ggtitle("Distribucion basados en Tipo 2") +
  coord_flip()
```




Número de Pokemon legendarios según su tipo primario (type1)

```
df %>%
  filter(is_legendary == 1) %>%
  ggplot(aes(type1)) +
  geom_bar(aes(fill = ..count..)) +
  scale_fill_gradient(low = "lightblue", high = "darkblue") +
  # Gradiente de colores
  theme(axis.text.x = element_text(angle = 90, hjust = 0)) +
  ggtitle("Numero de Pokemon Legendarios del Type-1")
```



El siguiente gráfico muestra la cantidad de Pokémon legendarios según su tipo primario (type1).

```
df %>%
  filter(is_legendary == 0) %>%
  ggplot(aes(type1)) +
  geom_bar(aes(fill = ..count..)) +
  scale_fill_gradient(low = "orange", high = "red") + # Gradiente de colores
  theme(axis.text.x = element_text(angle = 90, hjust = 0)) +
  ggtitle("Numero de Pokemon No Legendarios del Type-1")
```



Este nuevo gráfico muestra la cantidad de Pokémon no legendarios según su tipo primario (type1). Vemos que el tipo más común es Water, Normal, Grass y Bug.

B.3. Gráfico de dispersión – Scatterplots

B.4. Diagramas de Caja o Boxplots

B.5. Mapas de calor

B.6. Matriz de Correlación